סיווג משלחי יד מנתוני סקר

כדי לצמצם עבודת סימול ידנית,
נבנה חיזוי משלח יד לשאלונים חדשים.

מטלת קבלה לתפקיד מדען נתונים בכיר
Or Shulrufer

200 רשומות סינתטיות 18 שדות יעד רב-מחלקתי

מטרת ההגשה: החלטות מבוססות נתונים ותהליך שניתן להריץ מחדש

שלוש אי-ודאויות שמכתיבות את התהליך

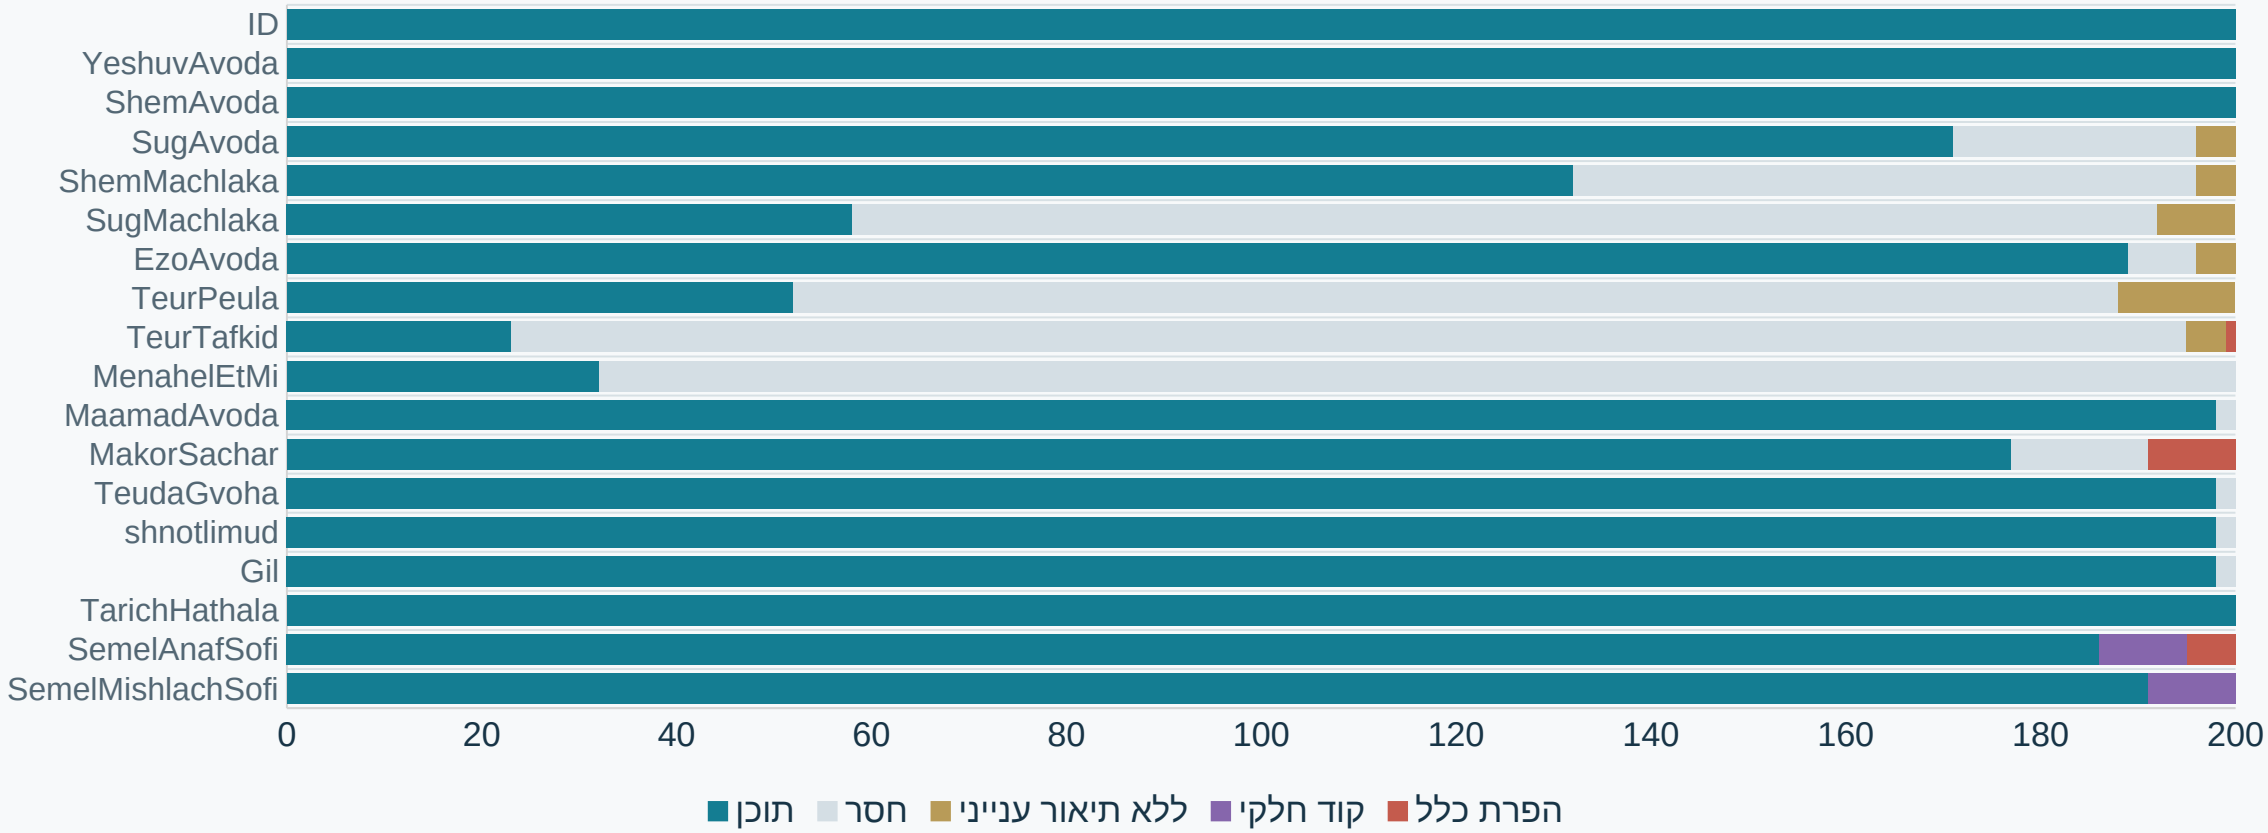
כדי לא להמציא מידע חסר, כל החלטה נשענת על מה שמתועד ועל גבולות הקובץ.

המשמעות במטלה	מה חסר כדי להכריע	החלטה במימוש
שאלונים חלקיים ושידורים חוזרים	מזהה נסקר ומועד שידור	שומרים שורות ומפרידים תיאורים חוזרים ב-CV
סימול ידני עם טעויות ועם X	אמת מאומתת ומזהה סמלן	קודים מלאים לאימון, חלקיים להצעות לסמלן
ענף כלכלי של מקום העבודה ומשלח היד של האדם	מועד זמינות קוד הענף והגדרת תקן הקודים	משלח היד הוא היעד. קוד הענף נשמר לביקורת

התוצאה: הנחות מפורשות שניתן לבדוק בהטמעה

איכות הנתונים בכל 18 השדות

כדי להבחין בין חסר מותר לבין בעיית נתונים, כל תא מקבל מצב אחד בדוח המקור.



9 חריגות תחולה במקור השכר 5 קודי ענף קצרים 0 לא מתועד בתואר משרה

משמעות השדות קובעת את הייצוג

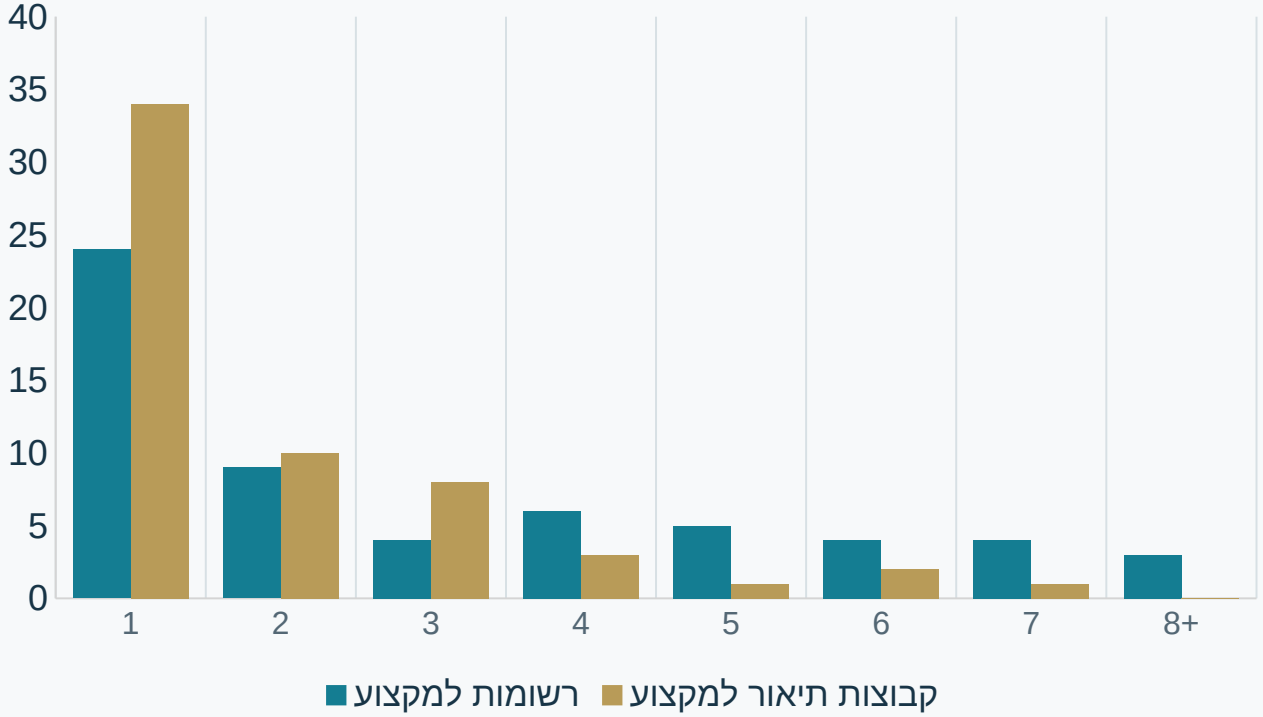
כדי לשמור על מידע שימושי, מפרידים תיאורים, ישויות, קודים וכמויות לפי Metadata.

סוג מידע	שדות	טיפול זהה בשני המסלולים
6 תיאורים	פעילות מקום ומחלקה, שם מחלקה, עבודה, פעולות ותואר	TF-IDF נפרד לכל שדה, בהמשך עם קבוצות או בלעדיהן
2 ישויות	יישוב ומקום עבודה	One-hot עם טיפול בקטגוריה חדשה
4 קודים	ניהול, מעמד, מקור שכר ותעודה	One-hot לפי תחומים מתועדים ותנאי תחולה
3 כמויות	גיל, שנות לימוד ושנת תחילת עבודה	חציון וקנה מידה נלמדים באימון
3 שדות מחוץ לקלט	ID, קוד ענף סופי וקוד משלח יד	נשמרים לחיבור תוצאות ולביקורת

TEXT אינו הוכחה לשדה חופשי. מעט ערכים אינם הוכחה לרשימה סגורה.

חזרות ומקצועות נדירים מגבילים את הבדיקה

כדי למדוד הכללה לתיאור חדש, אותו דפוס תיאור נשאר בצד אחד של כל חלוקה.



59 מקצועות
24 עם רשומה אחת
34 עם קבוצת תיאור אחת

156 רשומות לאימון
35 לבדיקה, מהן 7 בקוד שלא נצפה באימון
10 קפלי GroupKFold בתוך האימון

בדיקה אבחונית: accuracy של 0.812 לפי שורה, 0.586 לפי קבוצת תיאור

שני מסלולי הכנה על אותם שדות

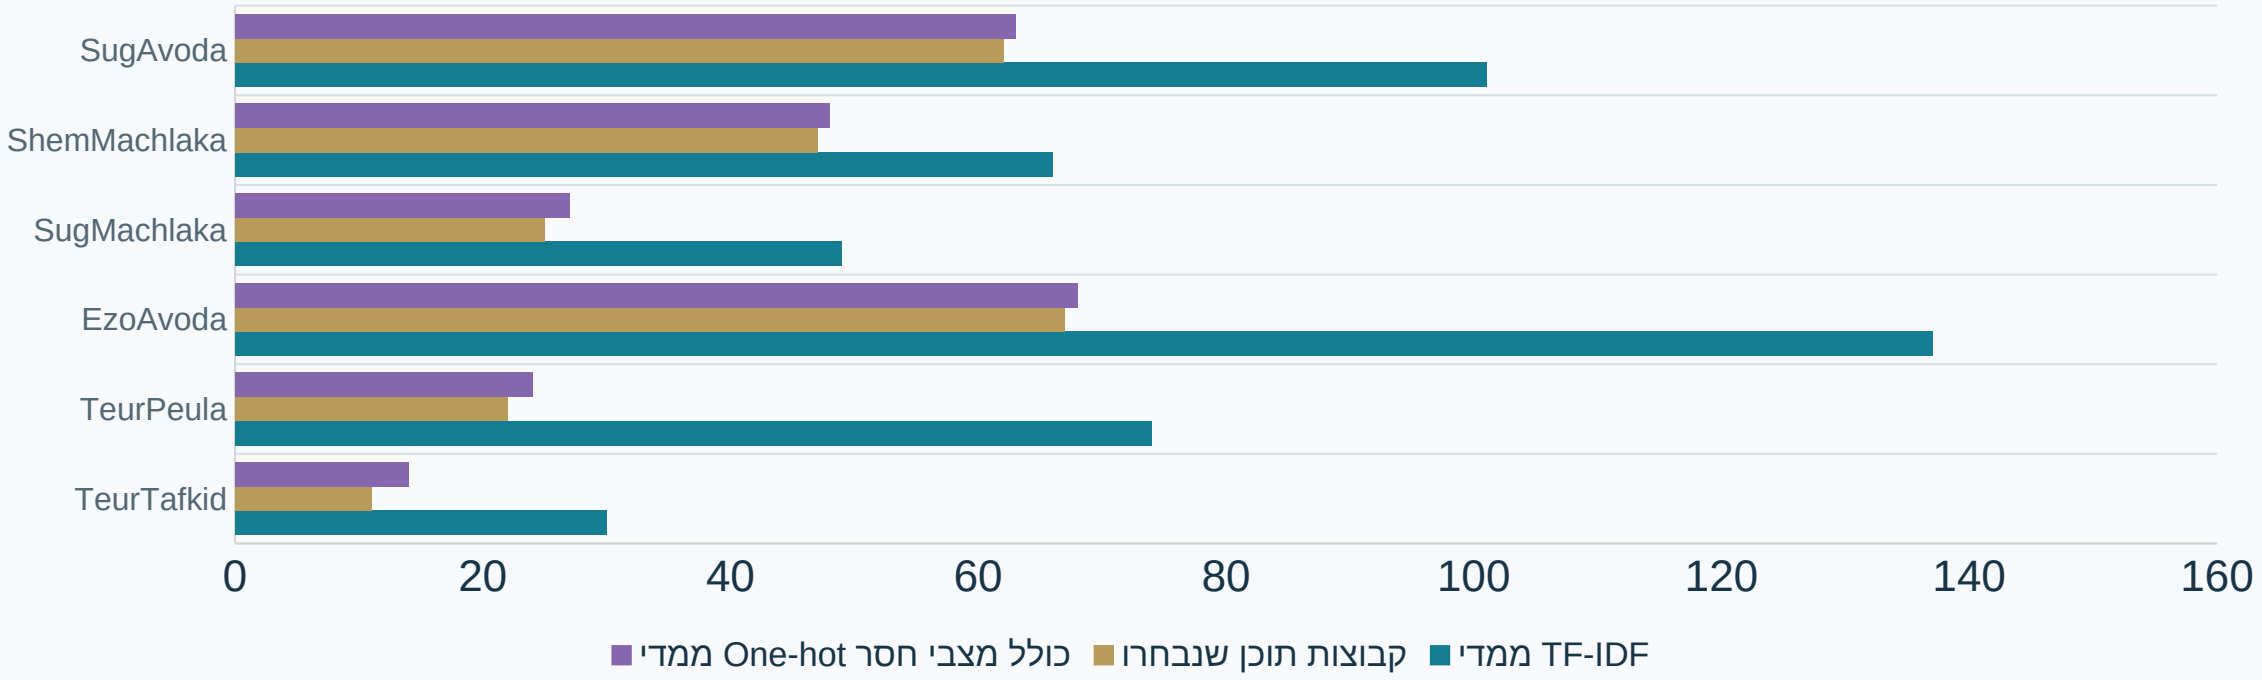
כדי לבדוק אם הקיבוץ שומר על הבחנות מקצועיות, משווים אותו ישירות למשקלי הטקסט.

שיקול	TF-IDF ישיר	קבוצות ואז One-hot
מה נשמר	משקל של כל מונח	זהות קבוצה לכל שדה
מתי עשוי להועיל	מילים נדירות שמבדילות בין מקצועות	ניסוחים חוזרים עם קרבה שימושית
מגבלה אפשרית	פיצול בגלל כתיב ומונחים חדשים	מיזוג מקצועות או קבוצות רבות מדי
מה מבוצע	TF-IDF גולמי, וגם בדיקת L2	TF-IDF, נרמול L2, בחירת K וקידוד קבוצות
בתרחיש של נתונים רבים	ייצוג דליל ומסווג שתומך בו	חיפוש K מוגבל ושיוך באצוות

כל העיבוד הנלמד מותאם מחדש בתוך קפל האימון

בחירת קבוצות לפי יחס הפיזורים

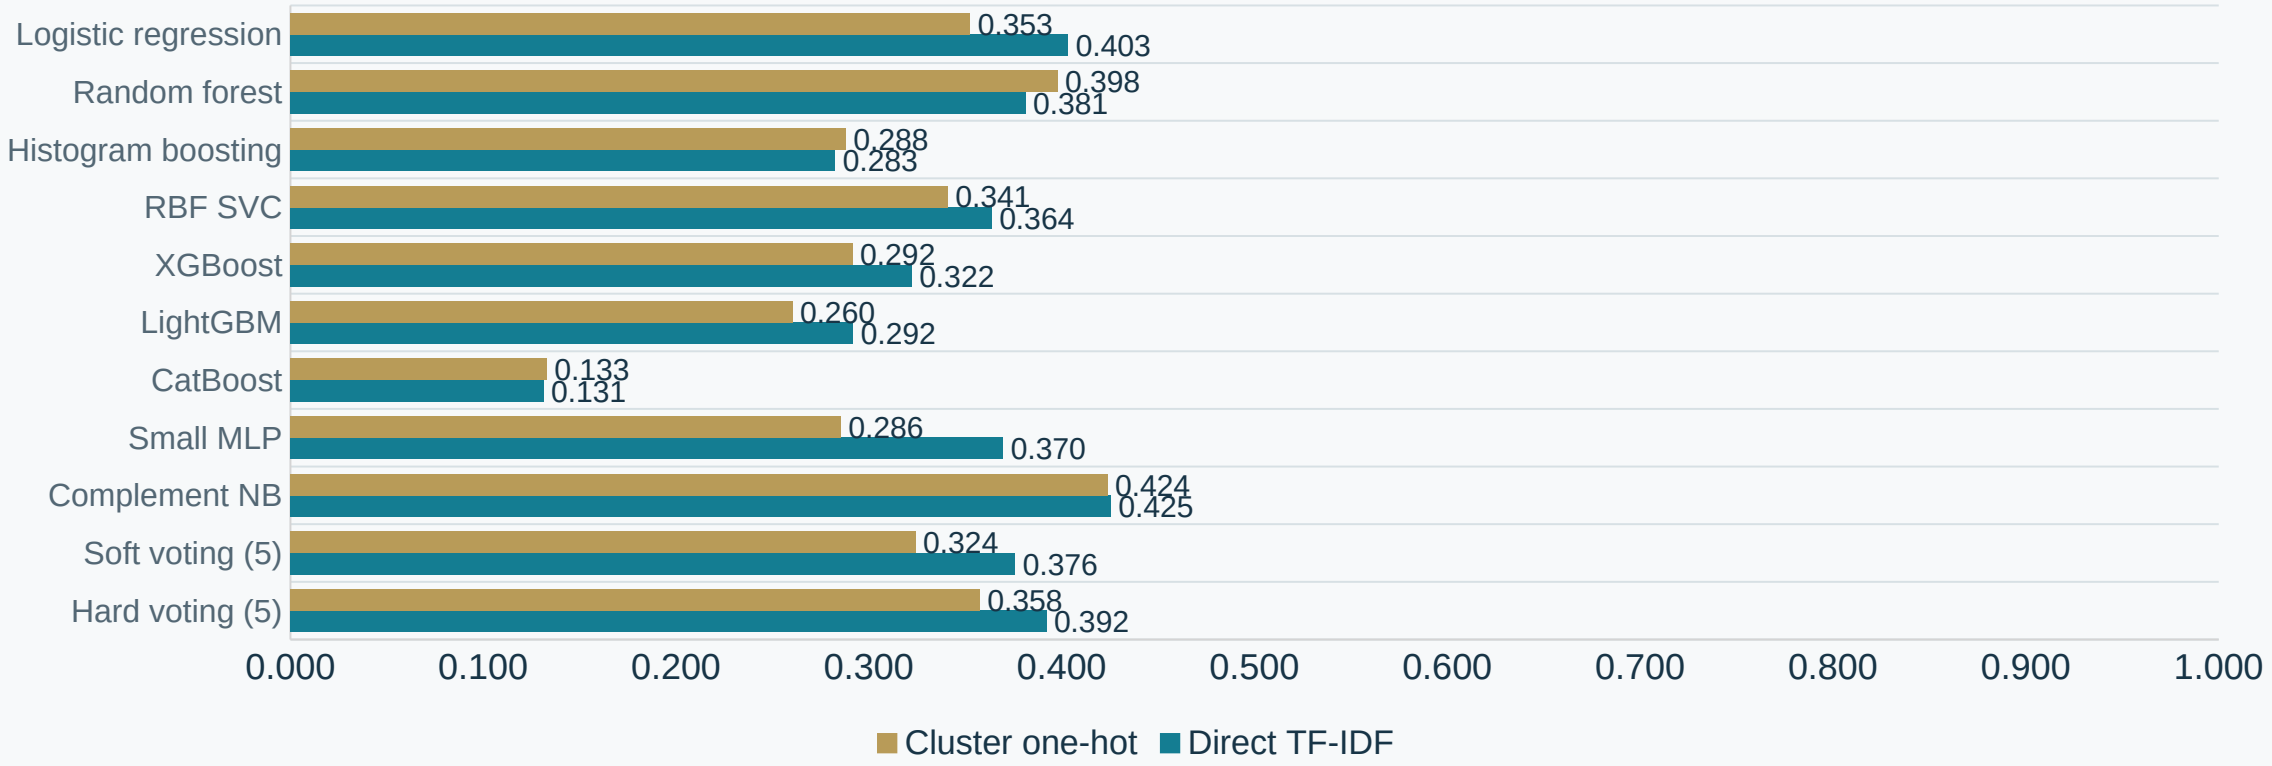
כדי להעדיף קבוצות קומפקטיות ומופרדות, בוחרים את ציון Calinski-Harabasz הגבוה בין ערכי K שנבדקו.



המדד עשוי לבחור כמעט קבוצה לכל ניסוח.
התועלת לסיווג המקצוע נבחנת בנפרד, בוולידציה.

השוואת כל המודלים בשני המסלולים

כדי לבדוק אילו הנחות מתאימות לנתונים, משווים את משפחות המודלים על אותם קפלים.

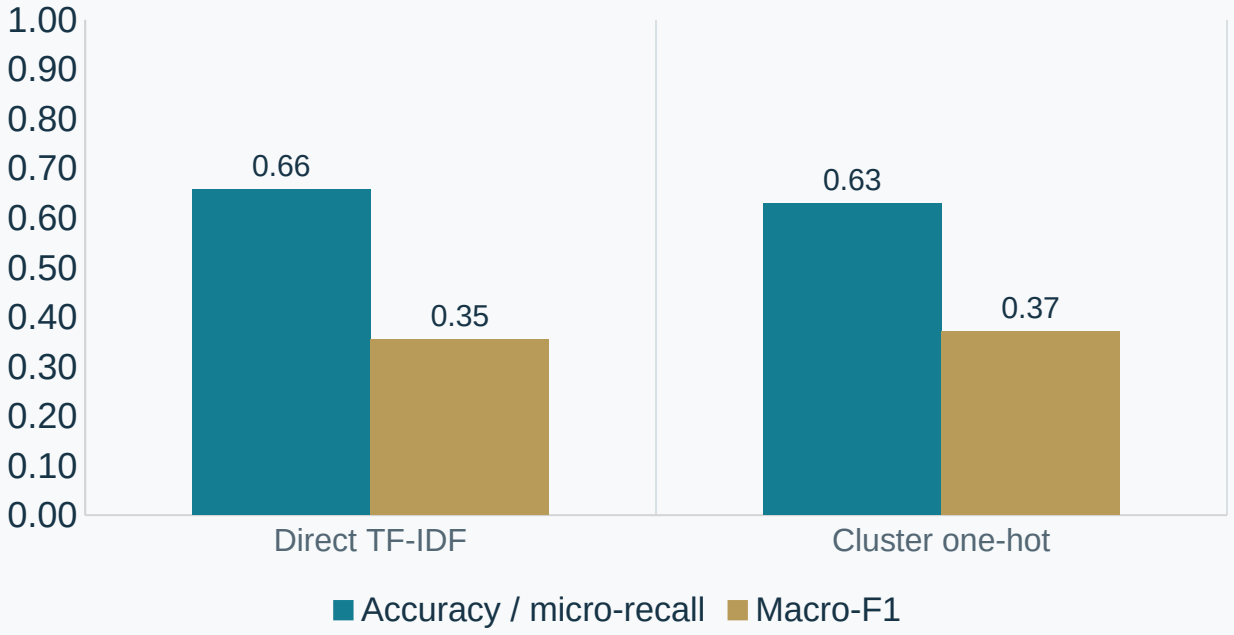


172 מועמדים כולל קו בסיס. בכל פרמטר: ברירת מחדל ושתי חלופות מנומקות.

CV macro-F1: שני מסלולי Complement NB כמעט זהים, 0.425 ו-0.424.

בדיקת התחזיות והצעות לסמלן

כדי לראות את תוצאת הבחירה על רשומות שלא שימשו לכוונון, מפעילים את המפרטים שנבחרו ב-CV פעם אחת על הבדיקה.



בחירה לפי CV
Complement NB
Direct TF-IDF

9 רשומות עם X מקבלות הצעות לסמלן. אין עבורן אמת מלאה לחישוב ציון.

שני אנסמבלים נפרדים חוזים אותה רשומה חדשה ללא קוד אמת.

35 רשומות בדיקה, מהן 7 עם קוד שלא נצפה באימון. אין מכאן הבטחת איכות תפעולית.

הטמעה מדורגת עם מדידת טעויות אמיתית

כדי להפחית עבודת סימול בביטחון, מתחילים בסיוע לסמלן ומרחיבים סמכות רק לאחר אימות.

הסיבה	הפעולה הבאה	תוצר שמאפשר להתקדם
שידורים חוזרים אינם מזוהים בקובץ	מזהה נסקר ושידור, מועד שידור ומזהה סמלן	חלוקה אמיתית לפי נסקר וזמן
היעד הידני כולל שגיאות וקודים חלקיים	סימול כפול והכרעת מומחה במדגם	מדגם אמת לבחירה, כיול והערכת טעויות
תרחיש של אלפים עד מיליון רשומות	מדגם מייצג, אצוות ובחינת ייצוג דליל	מדידת איכות, זמן וזיכרון לפי נפח
הסימולציה אינה מבטיחה איכות תפעולית	פיילוט הצעות, רישום תיקונים וניטור שינויי נתונים	יחס מדוד בין חיסכון בזמן, כיסוי וטעויות

GitHub-המחברת המלאה והתחזיות ב